

המחלקה להנדסת חשמל ואלקטרוניקה

פרויקט גמר בתכנ הנדסי - סטאז' מחקרי


Covid-19 Detection in Chest X-Ray images



מוגש ע"י : משה ניסים


חתימה :

בהנחיית : ד"ר אמיר אדלר


חתימה :

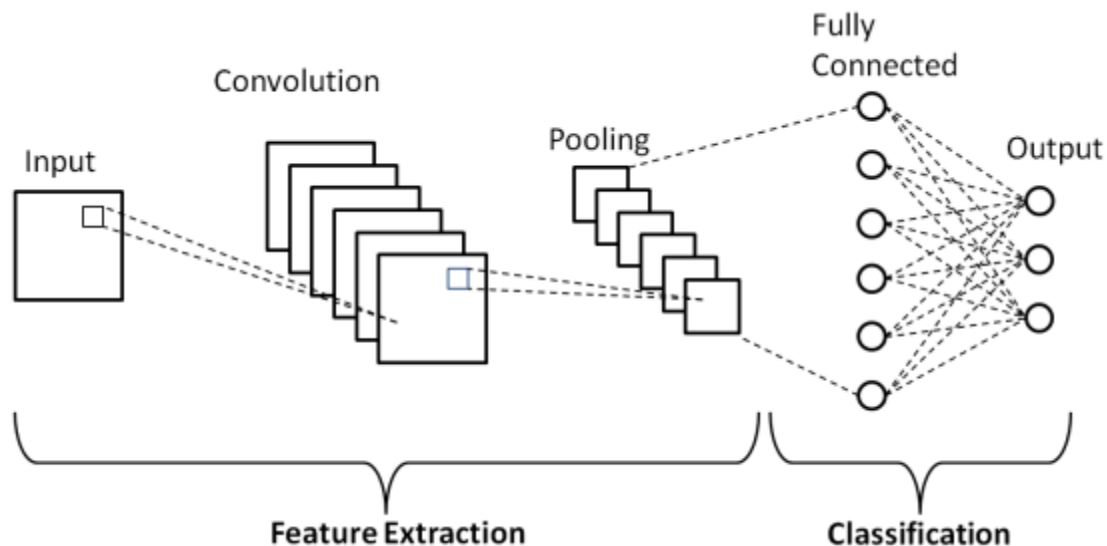
תאריך עברי : י"ג בתשרי תשפ"א

תאריך לועזי : 19.09.2021

הוגש לשם מילוי חלקי של הדרישות לקבלת תואר
"בוגר במדעים B.Sc. בהנדסת חשמל ואלקטרוניקה"

תקציר

מחקר זה עוסק בפיתוח פתרונות באמצעות למידה עמוקה בדיוק גבוה לסיווג דלקת ריאות מסוג Covid-19 בתצלומי רנטגן כאשר תוצאות הסיווג הן: חיובי-דלקת ריאות (Pneumonia), חיובי-דלקת ריאות מסוג Covid-19, שלילי. בתקופה זו כאשר העולם מתמודד עם נגיף הקורונה אשר חוליו נמצאים בקבוצת סיכון גבוהה יותר לחלות בדלקת ריאות, החשיבות לדיוק וזמן הפיענוח של הבדיקה גובר. נציע מספר רשתות למידה עמוקה (CNN) אשר יסווגו תצלומים בהתאם לקטגוריות המוגדרות. את הרשתות נאמן עם תמונות צילומי רנטגן אמיתיות מבסיסי נתונים קיימים של צילומי X-RAY של חולי Covid-19 (וכן ללא קורונה) אשר אליהם נוסיף תמונות מעובדות בשיטות Data Augmentation על מנת ליצור בסיס נתונים מגוון כך שבסך הכל הוא יכלול מספר אלפים בודדים של תמונות. במהלך בניית הרשתות נבחן מספר ארכיטקטורות הכוללים שיטות Resnet/CNN יחד עם שימוש ב-transfer learning מתוך מטרה להגיע לתוצאות אבחון בדיוק גבוה של מעל 90%. לבסוף נבדוק את הרשתות הנ"ל באמצעות סט בדיקה מותאם ונדון בתוצאות שהושגו וכיצד ניתן להגיע לתוצאות טובות יותר.



בתמונה: המחשה של רשת נוירונים מלאכותית. מקור [13]

תוכן עניינים

1	מבוא	1
2	1.1 עקרונות CNN	2
2	1.2 מושגי יסוד	6
6	2. תיאור המערכת	6
6	2.1 מפרט פונקציונלי	7
7	2.2 מפרט טכני	8
8	3. מטלות הנדסיות	8
8	3.1 מטלות הנדסיות ברמת מפרט דרישות	9
9	3.2 שלבי תכנון	10
10	3.3 תכנון-אב	11
11	3.4 בניית בסיס נתונים	12
12	3.5 עיבוד מקדים של בסיס הנתונים	13
13	3.6 גישת K-Fold cross-validation	14
14	3.7 בחינת ארכיטקטורות של רשתות למידה עמוקה	24
24	3.8 תהליך אימון הרשתות	25
25	4. סימולציות ותוצאות	27
27	4.1 Standard CNN Ver 1	29
29	4.2 Xception	31
31	4.3 YOLO	34
34	4.4 DenseNet	36
36	4.5 VGG16	38
38	4.6 Standard CNN Ver2	41
41	5. בעיות הנדסיות ודרכי התמודדות	42
42	6. סיכום ודיון	42
42	6.1 הליך קבלת החלטות לאורך הפרויקט	43
43	6.2 תרומת עבודתו של הסטודנט	43
43	6.3 שינויים עתידיים דרושים והצעות לשיפור	45
45	6.4 מסקנות	46
46	7. סימוכין	48
48	8. נספחים	49
49	9. קורות חיים	

איורים

1	Figure 1: תצלום חזה רנטגן המכיל Covid-19
2	Figure 2: תיאור פעולת קונבולוציה ברשת
3	Figure 3: מאפיין לאחר מעבר בשכבת Max Pooling
4	Figure 4: שימוש ב-Dropout
5	Figure 5: העברה לממד יחיד וכניסה לשכבות FC
5	Figure 6: שימוש ב-SoftMax
8	Figure 7: תרשים מלבנים של המערכת
10	Figure 8: תרשים זרימה של בניית רשת CNN וניתוח תוצאות
11	Figure 9: דגימות רנטגן משלושת הקטגוריות לסיווג
12	Figure 10: יצירת תמונה מעובדת באמצעות שימוש ב-Data Augmentation
13	Figure 11: חלוקה לקבוצות לפי 5-Fold CV
14	Figure 12: קונבולוציה קלאסית
17	Figure 13: קונבולוציה בערוצים מופרדים
17	Figure 14: שימוש ב-skip connections
18	Figure 15: ארכיטקטורת Xception
19	Figure 16: ארכיטקטורת YOLO
19	Figure 17: הזרמת מאפיינים לאורך השכבות
21	Figure 18: ארכיטקטורות DenseNet השונות
22	Figure 19: ארכיטקטורת VGG16
24	Figure 20: VGG16 מבנה הרשת
26	Figure 21: המחשת פרמטרים בדוח סיווג
27	Figure 22: דיוק והפסד- רשת סטנדרטית
28	Figure 23: CM רשת סטנדרטית
29	Figure 24: דיוק והפסד Xception
30	Figure 25: Xception CM
31	Figure 26: דיוק והפסד YOLO
32	Figure 27: YOLO CM
33	Figure 28: YOLO CM לאחר שיפור
34	Figure 29: דיוק והפסד DenseNet
35	Figure 30: DenseNet CM
36	Figure 31: דיוק והפסד VGG16
37	Figure 32: VGG16 CM
38	Figure 33: דיוק והפסד רשת סטנדרטית- גרסה 2
39	Figure 34: CM רשת סטנדרטית- גרסה 2

טבלאות

7	Table 1: טבלת מכלולים
9	Table 2: שלבי תכנון
11	Table 3: פירוט בסיס הנתונים
15	Table 4: רשת CNN סטנדרטית
17	Table 5: ארכיטקטורת Xception
22	Table 6: גרסה 2 לרשת סטנדרטית
24	Table 7: בחירת פרמטרים לרשתות
25	Table 8: תוצאות המודלים
29	Table 9: דוח סיווג ממוצע- רשת סטנדרטית
31	Table 10: דוח סיווג ממוצע Xception

34	YOLO : דוח סיווג ממוצע	Table 11
36	DenseNet : דוח סיווג ממוצע	Table 12
38	VGG16 : דוח סיווג ממוצע	Table 13
40	רשת סטנדרטית גרסה 2 - דוח סיווג ממוצע	Table 14

משוואות

2	חישוב קונבולוציה	Equation 1
3	פונקציית אקטיבציה	Equation 2
3	חישוב תוחלת	Equation 3
4	חישוב שונות	Equation 4
4	נרמול ערכים	Equation 5
4	הכפלה והזזה	Equation 6
5	SoftMax אלגוריתם	Equation 7
6	פונקציית חישוב הפסד	Equation 8
14	מספר פרמטרים בכל שכבה	Equation 9
19	DenseNet ב סך כל הקשרים	Equation 10
26	accuracy	Equation 11
26	precision	Equation 12
26	recall	Equation 13
26	f1-score	Equation 14
44	הצעת אלגוריתם יציאה משופר	Equation 15

רשימת קיצורים

CCE- Categorical Crossentropy

CNN- Convolutional Neural Network

DL- Deep Learning

FC- Fully connected

FM- Feature Maps

ML- Machine Learning

Resnet- Residual Network

ReLU- Rectified Linear Unit

YOLO- You Look Only Once

1. מבוא

הלמידה העמוקה (DL) היא תחום מחקר בעולם המחשבים וספציפית בתחום "למידת המכונה" שמניח שהמחשב יכול ללמוד וללמד את עצמו, ממש כמו המוח האנושי. מטרתו הברורה של התחום הזה היא ליצור חיקוי ממוחשב של פעולת המוח האנושי.

המיוחד במערכות למידה עמוקה הוא היכולת שלהן ללמוד ולהשתפר כל הזמן בזכות עצמן. מפתחי מערכות כאלה בונים מעין "רשת סמנטית". זו מערכת שמחקה את הנורונים שבמוח האנושי וכאמור פועלת ולומדת כמוהו - ככל שהיא פועלת וככל שמשתמשים בה - היא משתפרת ו"יודעת" יותר. מדובר בתחום חדש יחסית בעולם של חקר המערכות הלומדות אשר נקרא גם "הלמידה החישובית" (ML). לטווח רחוק מטרת התחום היא פיתוח של מחשב שיוכל להחליף את החשיבה האנושית אשר תהיה מסוגלת לזהות תבניות ודפוסים בדיבור, תמונות, צלילים ועוד סוגי מידע, שהמערכות מתקשות כיום לעבד ולטפל בהם.

במחקר זה ניקח את הטכנולוגיה של הלמידה העמוקה ונשתמש בה לצרכי ניתוח מהיר ומדויק של הנגיף Covid-19 אשר הפך למשימה קריטית בהתחשב בעלייה הקבועה בעולם במספר המאומתים בנגיף וכתוצאה מכך ההשפעה שנוצרה על הכלכלה העולמית ועל פעולותיהם של מקבלי ההחלטות בזירה הבינלאומית.

מטרתנו היא לבנות אלגוריתמי למידה עמוקה אשר יאתרו מיידית Covid-19 בתצלומי רנטגן (X-Ray) וזאת על מנת לסייע בזמן ניתוח התוצאות ודיוקם לאיתור הנגיף.

האלגוריתמים המוצעים יוכלו לפעול בעמדות מהירות, בקופות ובתי חולים מקומיים. המחקר ישתמש בתמונות של מקרים מאומתים כמו בתמונה המצורפת מטה על מנת לאמן את האלגוריתמים שניצור תוך מתן דגשים לתוצאות מהירות בדיוק גבוה.




Figure 1 : תצלום חזה רנטגן המכיל Covid-19. הנקודות המוקפות באדום מכילות את הדלקת שנגסה לאתר במחקר.

1.1. עקרונות CNN

רשת קונבולוציה עצבית היא אלגוריתם למידה עמוקה עשויה שכבות אשר מקבלת תמונה (קלט) ומייחס חשיבות ("משקל") להיבטים / אובייקטים שונים בתמונה. אלגוריתם זה מסוגל להבדיל בין האובייקטים (FM) השונים. הצורך בלעבד את התמונה באמצעות אלגוריתם זה נמוך בהרבה בהשוואה לאלגוריתמי סיווג אחרים. בעוד שבשיטות פרימיטיביות מסננים מתוכננים ב-"עבודת יד" ל-CNN יש את היכולת ללמוד את המסננים / מאפיינים הללו לבד באמצעות אימון.

הארכיטקטורה של CNN מקבילה לקישוריות של נוירונים במוח האנושי. נוירונים מגיבים לגירויים באזור הקרוב אליהם בלבד המכונה "שדה הקליטה". אוסף של שדות אלו מכסה את כל שטח הראייה (התמונה).

1.2. מושגי יסוד

• Conv2D :

בהקשר של CNN שכבת הקונבולוציה היא הליבה של הרשת העמוקה. השכבה משמשת כמעין פילטר נע אשר מוכפל בתמונת הקלט הנכנסת לשכבה. הפילטר הוא בעצם חלון בעל ערכים נלמדים בתהליך האימון בצורה עצמאית. תהליך זה נועד על מנת לחלץ מאפיינים חשובים בתמונה כדי לסייע בתהליך הסיווג. פעולת הקונבולוציה בכל מיקום חלון מוציאה מכלל הפיקסלים ערך פיקסל יחיד אשר מועבר לשכבה הבאה. פעולת הקונבולוציה מתוארת באופן הבא :

$$F(i, j) = (I * K)(i, j) \sum_m \sum_n I(i + m, j + n) K(m, n) \quad (1)$$

Equation 1 : חישוב קונבולוציה

במשוואה הנ"ל I מתאר את מטריצת הפיקסלים כקלט (התמונה), K הוא הפילטר של השכבה בגודל $m \times n$ ו- F היא תוצאת הפעולה המתקבלת (FM).




Figure 2 : תיאור פעולת קונבולוציה ברשת

- **:Activation function**

שכבת האקטיבציה מקבלת את התוצאה משכבת הקונבולוציה. שכבה זו מחליטה באמצעות פונקציות שונות על עוצמת ההשפעה של אותו נוירון ברשת העמוקה. ישנם מספר פונקציות הניתנות לשימוש אך הבולטת שבהן מכונה ReLU. תיאור מתמטי של ReLU:

$$f(x) = \max(0, x) \quad (2)$$

Equation 2: פונקציית אקטיבציה

x מתאר את הקלט לשכבת האיקטוב. במידה והוא שלילי התוצאה ממנה תתאפס.

- **:MaxPool2D**

שכבה זו נועדה על מנת להוריד את מספר הפרמטרים ברשת ע"י צמצום בכמות הפיקסלים של הקלט בכניסה אליה. הפעולה הנ"ל נעשית ע"י חלון נע בגודל 2×2 אשר לוקח רק את הפיקסל בעל הערך המקסימלי בגבולות החלון. החלון נע בכל פעולה כזו בשתי משבצות של פיקסלים. מיקומה של שכבה זו בדרך כלל הוא לאחר שכבת קונבולוציה. ישנם טכניקות נוספות לצורך הורדת מספר הפרמטרים ברשת העמוקה כגון average pooling או L2-norm pooling אך הטכניקה הנ"ל היא הנפוצה ביותר.

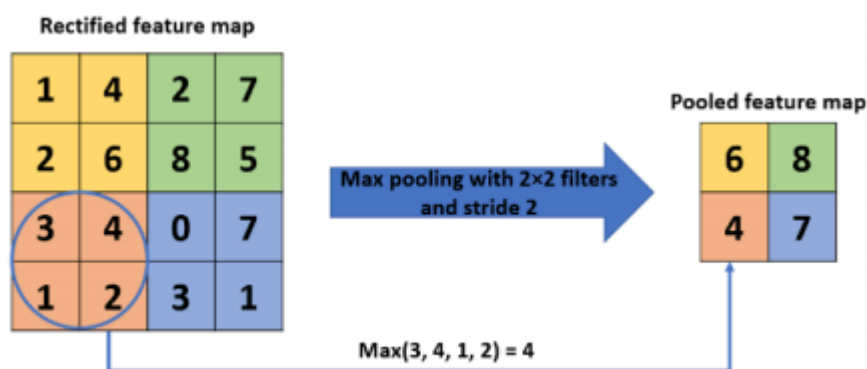


Figure 3: מאפיין לאחר מעבר בשכבת Max Pooling.

- **:BatchNormalization**

שכבה זו נועדה לייצב את הרשת ולהפוך אותה מהירה יותר. כשמה היא מנרמלת את ערכי הדגימות בכניסה ושמה אותם באותו קנה מידה. נתאר את האופי המתמטי של פעולת הנרמול ע"י סדרת משוואות: חישוב תוחלת:

$$\mu_B = \frac{1}{m} \sum_{i=1}^m x_i \quad (3)$$

Equation 3: חישוב תוחלת

חישוב שונות:

$$\sigma_B^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2 \quad (4)$$

Equation 4 : חישוב שונות

פעולת נרמול :

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} \quad (5)$$

Equation 5 : נרמול ערכים

ולבסוף הכפלה והזזה :

$$y_i = \gamma \hat{x}_i + \beta \quad (6)$$

Equation 6 : הכפלה והזזה

הפרמטרים γ, β הם פרמטרים נלמדים בתהליך הנרמול והפרמטר ϵ הוא קבוע אשר מתווסף לצורך יציבות נומרית. x_i הוא הקלט לשכבת הנרמול.

• Dropout :

דרך פשוטה למניעת overfitting ברשת היא שימוש ב-Dropout. באמצעות פונקציה זו מתעלמים באופן רנדומלי מנוירונים מסוימים בתהליך האימון. כך למעשה מונעים מהרשת להיות רגישה לסט תמונות ספציפי ויוצרים הכללה. באפשרות המשתמש לבחור את אחוזי הנוירונים שיבוטלו בצורה אקראית ע"י פונקציה זו.




Figure 4 : שימוש ב-Dropout

• Flatten :

רגע לפני המעבר לשכבות FC המידע עובר בשכבה זו אשר משטחת את הממד בכניסתה לזווקטור ארוך יחיד על מנת להעביר אותו לצורך עיבוד סופי לשכבות FC הממוקמות בסוף הרשת.

• Fully connected (Dense) :

בשכבה זו ישנו חיבור של כל נוירון מהשכבה הקודמת לכל נוירון בשכבה הנוכחית וכל ערך למעשה תורם את חלקו בתהליך הלמידה של הרשת. ברשתות הפופולריות של למידה עמוקה כמה

מהשכבות האחרונות של הרשת הן שכבות FC אשר היציאה מהאחרונה שבהן מועברת לפונקציית אקטיבציה המכונה SoftMax בסוף הרשת אשר אחראית על הסיווג הסופי לקבוצות.




Figure 5: העברה לממד יחיד וכניסה לשכבות FC.

• SoftMax:

פונקציית אקטיבציה זו אחראית על הסיווג הסופי ברשת. עקרון פעולתה היא הפיכת הקלט בכניסה (ווקטור בעל K ערכים- חיוביים, שליליים או אפסים) לווקטור באורך זהה בעל ערכים בתחום [0-1] בהתאם לערכים בכניסה. הערכים המתקבלים הם למעשה הסתברויות שסכומם יחד הוא 1. הערך בעל ההסתברות הגבוהה ביותר הוא הקבוצה אליה תשוך התמונה בכניסת הרשת.

נוסחת האלגוריתם היא:

$$\sigma(\vec{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} \quad (7)$$

Equation 7: אלגוריתם SoftMax

\vec{z} - הווקטור בכניסה לפונקציה

z_i - ערכי ווקטור הכניסה

K - מספר קבוצות לסיווג




Figure 6: שימוש ב SoftMax

• Loss function:

פונקציה זו נועדה לשערך את אחוזי השגיאה ברשת העמוקה. הפונקציה מחשבת את הגרדיאנט שמעדכן את המשקלים של הרשת במהלך האימון. ישנם מספר פונקציות לחישוב loss ברשת ובמחקר נתמקד ב-Categorical Crossentropy (CCE) המותאם לסיווג של כמה קטגוריות ביציאת הרשת. הפונקציה ממוקמת בצמוד לאקטיבצית SoftMax בסוף הרשת ומסתמכת על חישובי ההסתברויות של האקטיבציה. ההסתברויות מוצגות באמצעות one-hot vector כך שלמעשה רק קבוצה אחת מקבלת ערך גבוה בכל סיווג. ההפסד מחושב לפי הנוסחה הבאה:

$$CCE = - \sum_{i=1}^n t_i * \log(p_i) \quad (8)$$

Equation 8: פונקציית חישוב הפסד

t_i - ערך הסיווג האמיתי

p_i - הערך ההסתברותי

n - מספר הקבוצות לסיווג

המטרה היא להקטין את ההפסד ע"י עדכון משקלי הרשת על מנת לסווג בצורה מדויקת.

2. תיאור המערכת

2.1. מפרט פונקציונלי

- יצירת רשתות למידה עמוקה לסיווג Covid-19 ודלקת ריאות מסוג Pneumonia.
- הרשתות יספקו ביצועים על בסיס נתונים רחב המכיל אלפי תמונות.
- כל רשת תרוץ מספר פעמים על מנת לקבל תוצאות אופטימליות ומדויקות ככל שניתן.
- יצירת ארכיטקטורות מסוג CNN.
- יצירת ארכיטקטורות מסוג RESNET המבוססות על skip connections.
- כל ארכיטקטורה תלמד לסווג כל תמונה לאחת משלושת הקטגוריות: Covid-19, Normal, Pneumonia.

2.2. מפרט טכני

• טבלת פירוט מכלולי המערכת

שם המכלול	תיאור	פרמטרים
ImageDataGenerator	פונקציה המאפשרת להגדיל את סט התמונות בזמן האימון על מנת ליצור בסיס נתונים אקראי לאימון הרשת. בנוסף מודל זה מאפשר עיבוד מקדים של התמונות כגון שינוי גודל התמונה הנכנסת לרשת ונרמול פיקסלים.	<ul style="list-style-type: none"> • Resize • Rescale • Data Augmentation arguments • Target size • Batch size
CNN	רשת למידה עמוקה אשר מסווגת תמונות לשלושה סוגי קטגוריות.	<ul style="list-style-type: none"> • Epochs • Filters • Input shape • Padding • Activation • Kernel • Strides • Dropout • Learning rate • Loss
CM tool	כלי ניתוח אשר יציג את תוצאות הסיווג של סט הבדיקה בצורת טבלה	<ul style="list-style-type: none"> • Classes

Table 1: טבלת מכלולים

• תרשים מלבנים

תרשים מלבנים של אלגוריתם למידה עמוקה אשר נבנה במהלך עבודת המחקר. בתרשים ניתן לראות את עבודת ההכנה על תמונת הקלט ולאחר מכן הכנסתה אל הרשת וסיווג בהתאם לביצועי הרשת המאומנת.




Figure 7 : תרשים מלבנים של המערכת

• עקרון פעולת המערכת

- פעולת המערכת מתחלקת לשני חלקים עיקריים :
- תהליך האימון- התהליך העיקרי בו הרשת לומדת מבסיס הנתונים הנכנס אליה כקלט. תהליך זה מדמה תהליך למידה של נוירונים במוח וקובע את רמת הביצועים של הרשת המאומנת. תהליך האימון מתבצע באמצעות "קילוף" של התמונות למאפיינים ע"י פילטרים נלמדים וחשוב הסתברויות לכל מאפיין בתמונה.
 - תהליך סיווג התמונות- בתהליך זה כאשר הרשת (כמוצר מוגמר) סיימה את תהליך האימון היא מוכנה לסווג תמונות לפי שלושת הקטגוריות המוגדרות לה. העדיפות היא להכניס תמונות שלא נלמדו בתהליך האימון על מנת לבחון את ביצועי הרשת שהתקבלה. תהליך הסיווג מתבצע ביציאה מן הרשת ע"י פונקציית האקטיבציה SoftMax.

3. מטלות הנדסיות

3.1. מטלות הנדסיות ברמת מפרט דרישות

- כתיבת הצעת פרויקט.
- בניית בסיס נתונים של תמונות רפואיות X-RAY.
- בחינת ארכיטקטורות מסוג CNN עליהן תיבנה הרשת.
- בחינת ארכיטקטורות מסוג RESNET עליהן תיבנה הרשת.
- התאמת בסיס הנתונים לרשתות שנבחרו, בחינת שיטות לעיבוד מקדים של התמונות והרחבת כמות המידע (DATA AUGMENTATION).
- בניית רשתות לסיווג דלקת ריאות מסוג Covid-19.
- אימון הרשתות באמצעות בסיס הנתונים שנבנה.
- שיפור תוצאות האימון תוך שימוש בשיטות רגולריזציה לצורך הגעה לאחוז דיוק גבוה בתהליך הסיווג עם מבחני קרוס-ולידציה (Cross Validation).
- כתיבת ספר פרויקט ובניית מצגת.

3.2. שלבי תכנון

סעיף	מטלה	ביצוע	הערות
1	כתיבת הצעת פרויקט	✓	
2	בניית בסיס נתונים של תמונות רפואיות X-RAY	✓	
3	בחינת ארכיטקטורות מסוג CNN עליהן תיבנה הרשת	✓	
4	בחינת ארכיטקטורות מסוג RESNET עליהן תיבנה הרשת	✓	Architecture No. 2
5	התאמת בסיס הנתונים לרשתות שנבחרו, בחינת שיטות לעיבוד מקדים של התמונות והרחבת כמות המידע (DATA AUGMENTATION)	✓	
6	בניית רשתות לסיווג דלקת ריאות מסוג Covid-19	✓	
7	אימון הרשתות באמצעות בסיס הנתונים שנבנה	✓	
8	שיפור תוצאות האימון תוך שימוש בשיטות רגולריזציה לצורך הגעה לאחוז דיוק גבוה בתהליך הסיווג עם מבחני קרוס-ולידציה (Cross Validation)	✓	
9	בניית ארכיטקטורה מותאמת אישית על פי עקרונות CNN	✓	Architecture No. 1
10	שינויים ותוספות לארכיטקטורות הנתונות	✓	
11	כתיבת ספר פרויקט ובניית מצגת	✓	

Table 2: שלבי תכנון

3.3. תכנון-אב

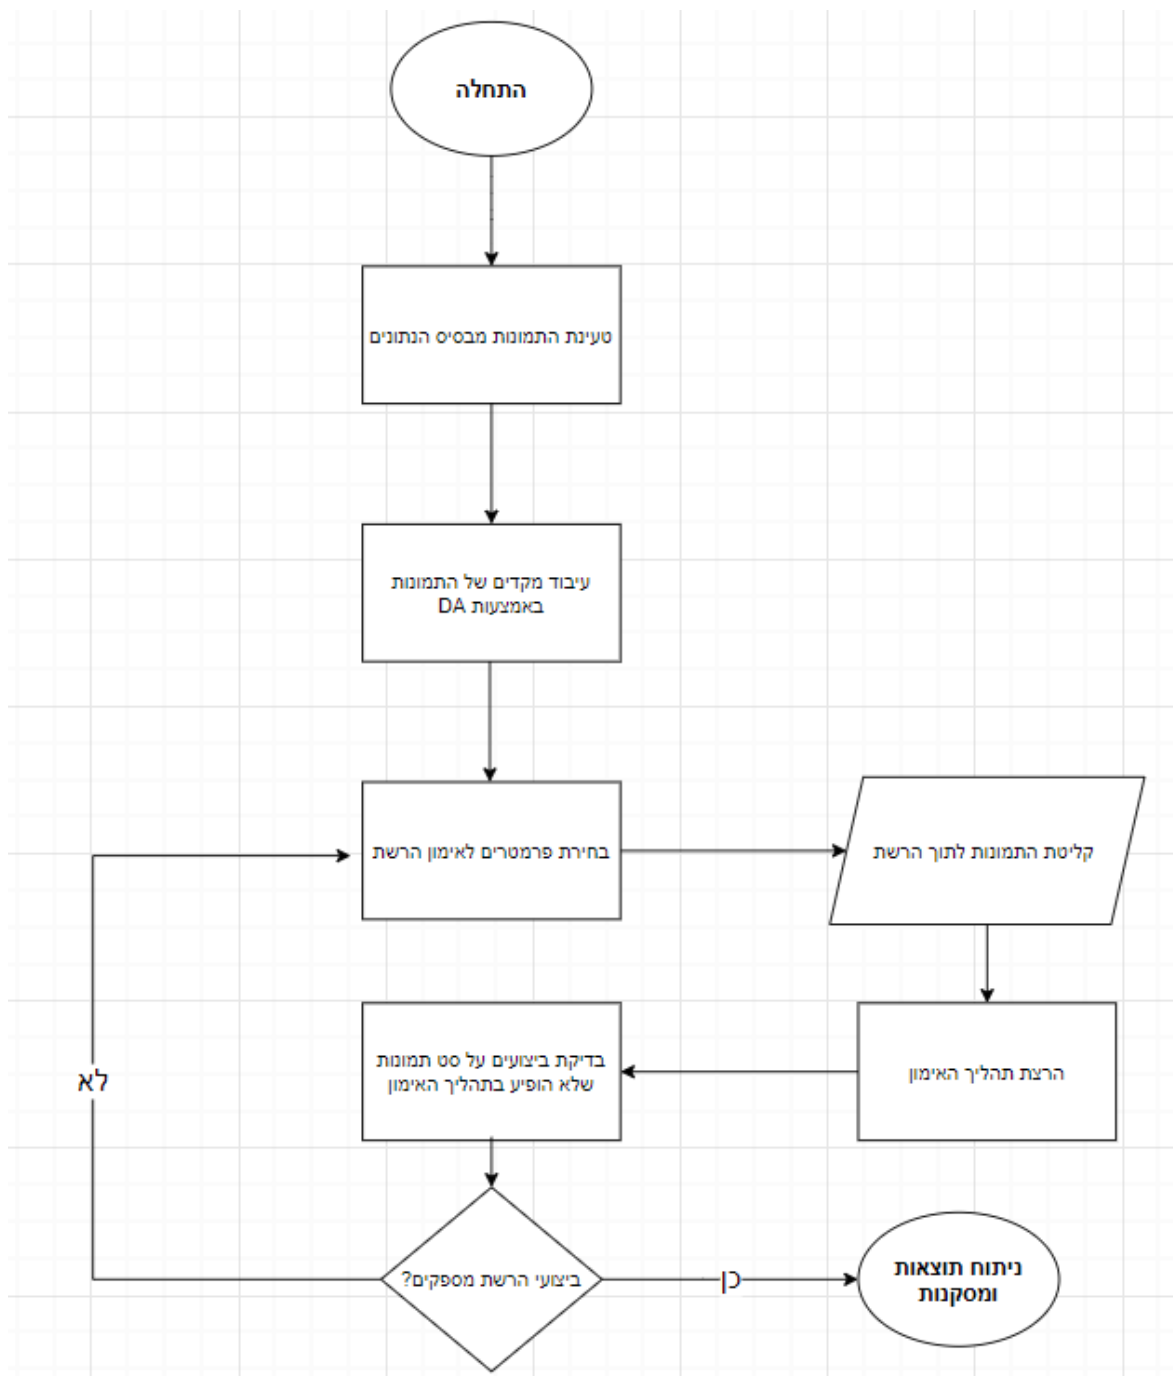


Figure 8: תרשים זרימה של בניית רשת CNN וניתוח תוצאות

3.4. בניית בסיס נתונים

מרכזו של אלגוריתם למידה עמוקה הוא הקלט שנכנס לרשת המתוכננת ולמעשה משמש כמו דלק להזנת הרשת. במחקר נעשה שימוש במספר מקורות [9], [10], [11] אשר יספקו בסיס רחב של תמונות רפואיות אמיתיות (7474 תמונות) של שלושה קטגוריות :

- Covid-19
- Pneumonia
- Normal

Pneumonia	Covid-19	Normal	סט נתונים
4273	1619	1582	סה"כ תמונות
3418	1299	1267	סט אימון
855	320	315	סט בדיקה

Table 3 : פירוט בסיס הנתונים




Figure 9 : דגימות רנטגן משלושת הקטגוריות לסיווג

3.5. עיבוד מקדים של בסיס הנתונים

על מנת ליצור בסיס נתונים גנרי ואקראי ככל שניתן בוצע שימוש בפונקציית הרחבה (Data Augmentation) אשר מטרתה ליצור תמונות מעובדות (על בסיס התמונות הקיימות) ולהגדיל את בסיס הנתונים בשיעור של פי מאה כך שהרשתות יאומנו בצורה אופטימלית וימנעו מ"התאמת יתר" לבסיס תמונות ספציפי (Overfitting), כך נוכל לייצר מודלים מאומנים אשר יזהו קלט שונה ומגוון ויסווגו בדיוק גבוה. להלן הפרמטרים בהם נעשה שימוש באמצעות הפונקציה :

פרמטר	ערך	פעולה
rescale	1./255	נרמול ערכי הפיקסלים בתמונה. מעבר מערכים [0-255] < [0=1]
rotation_range	32	סיבוב התמונה בטווח מעלות אקראי
featurewise_std_normalization	True	חלוקת הפיקסלים בסטיית התקן של כל סט הנתונים
width_shift_range	0.1	הסטה אופקית של התמונה באחוזים
height_shift_range	0.1	הזזה אנכית של התמונה באחוזים
shear_range	0.2	מתיחה אקראית של התמונה באחוזים
zoom_range	0.1	הגדלת התמונה באחוזים
channel_shift_range	20	מוסיף מספר אקראי בטווח לערכי הפיקסלים בערוץ
horizontal_flip	True	שיקוף אופקי
vertical_flip	False	שיקוף אנכי
fill_mode	constant	מילוי המסגרת של התמונה




Figure 10 : יצירת תמונה מעובדת באמצעות שימוש ב-Data Augmentation

3.6. גישת K-Fold cross-validation

על מנת ליצור סטים שונים של תמונות, בסיס הנתונים חולק בצורה אקראית לחמישה חלקים (5-Fold) וזאת כדי לאמן כל רשת מספר פעמים לצורך בחינת תוצאות האימון בצורה מעמיקה וניתוח של הרשת שהתקבלה.

Cross-validation היא שיטת דגימה אשר משמשת להערכת מודלים של למידה עמוקה המבוססים על בסיס נתונים מוגבל.

בגישה זו משתמשים בפרמטר K אשר מטרתו לקבוע את מספר הקבוצות אליהם נחלק את בסיס הנתונים שיצרנו. במחקר זה בחרנו בערך $K=5$ ועל כן השיטה הנבחרת היא 5-Fold CV. מטרתה העיקרית של הגישה היא הערכה כיצד המודל שנוצר לאחר תהליך האימון צפוי להתנהג על נתונים אקראיים שאיננו מכיר. האפשרות להכניס לרשתות במחקר זה נתונים שהן אינם מוכרות להן במשך 5 ריצות שונות עוזרת לנו לקבל אינדיקציה על הביצועים העתידיים של רשתות אלה ולהעריך אותן בצורה אמינה יותר לעומת הרצה בגישה הסטנדרטית של סט נתונים יחיד. לצורך השימוש בגישה ישנם מספר שלבי עבודה:

- פיצול בסיס הנתונים ל K -קבוצות.
- עבור כל קבוצה- סיווג הקבוצה כסט אימון או בדיקה כך שייווצרו $k-1$ קבוצות אימון וקבוצת בדיקה אחת.
- אימון הרשת באמצעות כל קבוצות האימון.
- הערכת הרשת באמצעות קבוצות הבדיקה.
- שמירת תוצאות ההערכה וחזרה על אותו תהליך עם בחירת קבוצות שונה.
- סיכום כל תוצאות ההערכה בהתאם להחלטת המשתמש.




Figure 11: חלוקה לקבוצות לפי 5-Fold CV

3.7. בחינת ארכיטקטורות של רשתות למידה עמוקה

בפרק זה מוצעים 6 ארכיטקטורות אשר נותחו באמצעות בסיס הנתונים שנבנה. בכל ארכיטקטורה שנבנתה מספר הפרמטרים בכל שכבה מחושב לפי האופן הבא :

$$x = (kernel_size * input_channels + 1) * filters \quad (9)$$

Equation 9 : מספר פרמטרים בכל שכבה

x - מספר הפרמטרים בשכבה הנוכחית

• Standard CNN Ver 1 :

ארכיטקטורת CNN קלאסית בבנייה מותאמת אישית המבוססת על שכבות קונבולוציה לחילוץ מאפיינים חשובים מהקלט.

הרשת מורכבת מחמישה שכבות קונבולוציה ו-pooling המעבירות את המידע לשכבות FC ולפונקציית הסיווג SoftMax בסוף הרשת.




Figure 12 : קונבולוציה קלאסית. מקור [5].

פירוט מרכיבי הרשת :

שם השכבה	גודל היציאה	מספר פרמטרים
Conv2D	(None, 150, 150, 32)	896
BN	(None, 150, 150, 32)	128
MaxPooling2D	(None, 75, 75, 32)	0
Conv2D	(None, 75, 75, 64)	18496
Dropout	(None, 75, 75, 64)	0
BN	(None, 75, 75, 64)	256
MaxPooling2D	(None, 38, 38, 64)	0

36928	(None, 38, 38, 64)	Conv2D
256	(None, 38, 38, 64)	BN
0	(None, 19, 19, 64)	MaxPooling2D
73856	(None, 19, 19, 128)	Conv2D
0	(None, 19, 19, 128)	Dropout
512	(None, 19, 19, 128)	BN
0	(None, 10, 10, 128)	MaxPooling2D
295168	(None, 10, 10, 256)	Conv2D
0	(None, 10, 10, 256)	Dropout
1024	(None, 10, 10, 256)	BN
0	(None, 5, 5, 256)	MaxPooling2D
0	(None, 6400)	Flatten
819328	(None, 128)	Dense
0	(None, 128)	Dropout
387	(None, 3)	Dense

Table 4: רשת CNN סטנדרטית

• ניסויים שבוצעו בארכיטקטורה הנ"ל:

תוספת שכבות קונבולוציה

תוספת שכבת Dropout

• **Xception:**

ארכיטקטורה זו מכילה 71 שכבות CNN המאומנות עם משקלי image-net. צורה זו משתמשת בשכבות קונבולוציה מופרדות בעומקן עם חיבורים בשיטת residual במקום שיטות הקונבולוציה הקלאסיות וכך נחסך זמן חישוב יקר.

• Depthwise Separable Convolution:

בשיטה זו מתבצעת קונבולוציה לכל ערוץ בתמונה בצורה עצמאית ונפרדת מהערוצים האחרים. ז"א שיתקבל ביציאה ממד זהה לכניסה מוכפל במס' הפילטרים.

• Pointwise Convolution:

פעולה זו מתבצעת באמצעות הקונבולוציה הקלאסית ע"י חלון בגודל 1x1xchannels על מנת להוריד את ממד הערוצים ל-1.

- הסבר כיצד מתבצע חסכון במספר החישובים :
עבור תמונת RGB בגודל $K \times K$ נפעיל חלון בגודל $d \times d$ בנפרד לכל ערוץ. בסוף התהליך נקבל $3 \times d \times d \times K \times K$ פעולות מתמטיות. לאחר מכן באמצעות פעולת Pointwise Convolution נשתמש בחלון $1 \times 1 \times 3$ פעמים (מספר הפילטרים שנבחר) שזו בכל ערוץ $K \times K$ פעמים. בסך הכל קיבלנו $(3 \times d \times d \times K \times K) + (1 \times 1 \times 3 \times K \times K \times N)$ פעולות מתמטיות. בשימוש בקונבולוציה קלאסית במקרה זה ההינו מקבלים סך של $3 \times d \times d \times K \times K \times N$ פעולות מתמטיות אשר היה מעמיס בצורה משמעותית על הרשת.
- הצבת הערכים הנבחרים בהרצת הרשת : $K=224, d=3$. עבור $N=32$ (מס' פילטרים) נקבל $(3 \times 3 \times 3 \times 224 \times 224) + (1 \times 1 \times 3 \times 224 \times 224 \times 32) = 6,171,648$ חישובים. אם נשווה זאת לקונבולוציה קלאסית נקבל $3 \times 3 \times 3 \times 224 \times 224 \times 32 = 43,352,064$ חישובים.
- Skip connections :
בארכיטקטורה הנ"ל קיימים החיבורים המכונים skip connections שמאפשרים לגרדיאנט לדלג על שכבות האקטיבציה באמצעות פעולת חיבור ישירה בין השכבות ובכך למנוע עומס על הרשת ואת דעיכת הגרדיאנט.
- Transfer learning :
גישה נוספת שממומשת בארכיטקטורה המוצגת היא transfer learning. בגישה זו לוקחים רשת שכבר מאומנת למטרה מסוימת לרשת המתוכננת למטרה שלנו. המשקלים אשר כבר מאומנים מהרשת הקודמת ישמשו כנקודת פתיחה לרשת הנוכחית. משקלי המקור נלקחו מבסיס נתונים הנקרא ImageNet. בבסיס הנ"ל ישנם מעל 14 מיליון תמונות מסווגות ל-1000 קטגוריות שונות וכך ניתן להתאים מודל כללי למטרת הרשת הנוכחית. היתרון בשימוש בשיטה הוא שניתן לקחת רשת מאומנת היטב שיודעת לחלץ מאפיינים ברמה גבוהה ולהתאים אותה לרשת אחרת נבנית כך שחילוץ המאפיינים יוטמע בה. בנוסף יושג זמן קצר יותר של אימון הרשת.
- ניסויים שבוצעו בארכיטקטורה הנ"ל :
שינוי מספר הנוירונים בשכבת Dense. $256 < 512$
שינוי אחוזי הזנחת הנוירונים בשכבת Dropout. $0.3 < 0.5$




Figure 13 : קונבולוציה בערוצים מופרדים. מקור [5].




Figure 14 : שימוש ב skip connections

פירוט מרכיבי הרשת :

שם השכבה	גודל היציאה	מספר פרמטרים
Xception	(None, 5, 5, 2048)	20861480
Flatten	(None, 51200)	0
Dropout	(None, 51200)	0
Dense	(None, 256)	13107456
Dense	(None, 3)	771

Table 5 : ארכיטקטורת Xception

מבנה הרשת המלא מתואר בתרשים הבא :

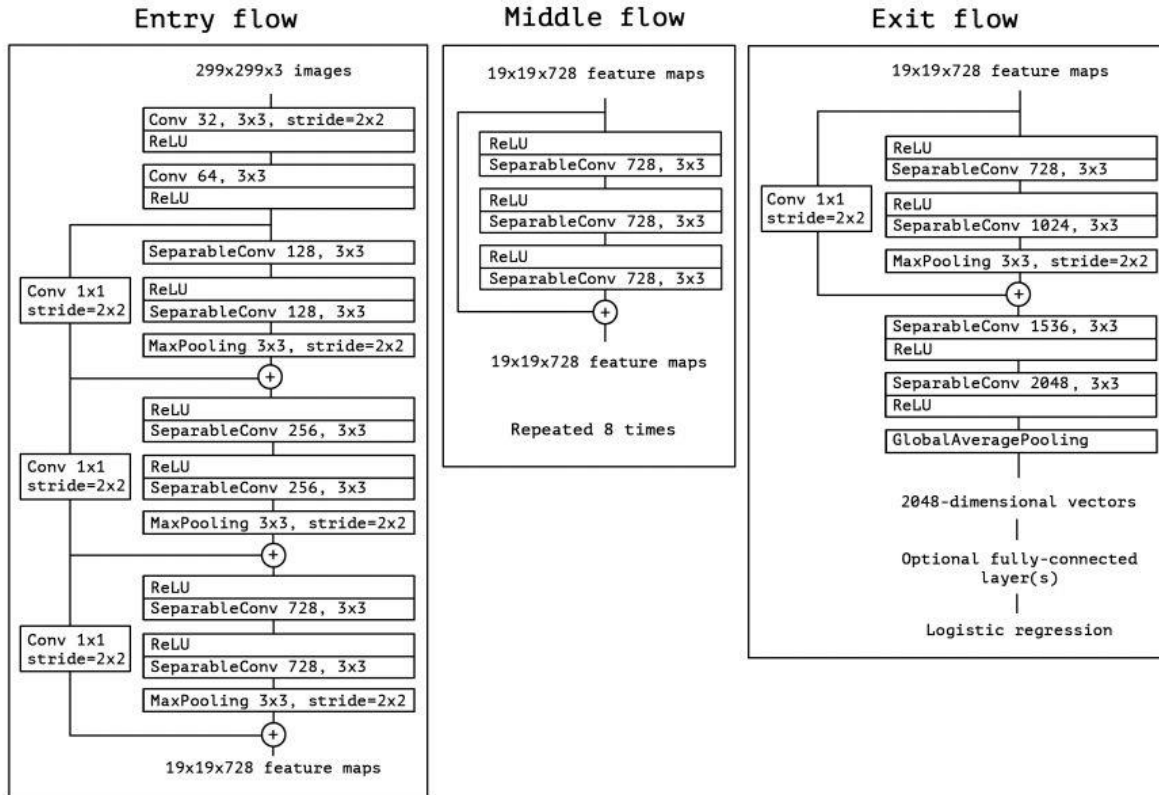


Figure 15: ארכיטקטורת Xception

• YOLO (You Only Look Once)

רשת סיווג זו מהרשתות היעילות ביותר לסיווג אובייקטים. נבנתה לראשונה בשנת 2015 ע"י ג'וזף רדמון וזכתה מיד לתשומת לב רבה בקרב חבריו לענף המחקר. התכונה שמייחדת את הרשת הנ"ל היא איתור אובייקטים בזמן אמת. האלגוריתם סורק תמונה שלמה במלואה ולאחר מכן מחלק אותה לאזורים וחווה הסתברויות לכל אזור בתמונה. הרשת הזו פופולרית מאוד בקרב חוקרים בתחום עקב התוצאות הגבוהות שהיא מגיעה אליהן. מעיקרי הרשת:

- YOLO היא רשת מהירה מאוד לעומת הרשתות האחרות ומשתמשת בקונבולוציה 1x1 לחילוף מאפיינים מהתמונה בשלמותה.
- הרשת רואה את התמונה בשלמותה במהלך האימון וכך היא מסתכלת על התמונה "מלמעלה" ולומדת מידע חיוני על כל מחלקה בתהליך הסיווג. בנוסף הרשת טועה פחות בחילוף מאפיינים הקשורים לרקע התמונה ועושה ניתוח גלובאלי ולא מקומי.
- YOLO לומדת לסווג מאפיינים עם רמת הכללה גבוהה כך שהיא יכולה להתמודד עם קלטים מגוונים וחדשים שאיננה מכירה עם אחוז שגיאה נמוך.




Figure 16: YOLO architecture

• ניסויים שבוצעו בארכיטקטורה הנ"ל:

שינוי בגודל החלונות בשכבות קונבולוציה: (1,1) <- (3,3)

שינוי שכבת הסיווג ביציאת הרשת: Linear <- SoftMax

• DenseNet121:

מטרתה של הארכיטקטורה הנ"ל היא הזרמת המאפיינים לאורך כל הרשת. כלומר כל שכבה מעבירה מאפיינים לכל השכבות אחריה בהמשך הרשת. מספר הקשרים ברשת יחושב באופן הבא:

$$X = \frac{I(I+1)}{2} \quad (10)$$

Equation 10: סך כל הקשרים ב DenseNet

X - מספר הקשרים ברשת

I - מספר השכבות הקיימות בכלל הרשת

אם נשווה את מספר הקשרים לשיטות המסורתיות נראה שקיימים בהן I קשרים בלבד.




Figure 17: הזרמת מאפיינים לאורך השכבות

תכונה נוספת של רשת מסוג זה היא שימוש בשרשרת של המאפיינים המועברים בין השכבות ולא בסיכום שלהם בשונה מרשתות Resnets ובכך מורידה את כמות החישובים ברשת. תכונות הרשת:

- Dense block :

בארכיטקטורה ישנם כ-4 בלוקים של Dense המורכבים משתי שכבות קונבולוציה בעלי חלונות 1×1 ו- 3×3 . בנוסף ישנם שכבות אקטיבציה (ReLU) ונרמול (BN) הפועלות על המשקלים ביציאה מהקונבולוציות הנ"ל.

- Transition block :

שכבה זו משמשת כשכבת מעבר על מנת לשמור על קצב האימון של הרשת. השכבה מורידה את קצב דגימת המאפיינים על מנת למנוע עומס על הרשת והתשה בביצועיה. התהליך נעשה באמצעות חלון קונבולוציה 1×1 ושכבת 2×2 pooling כך שמעבר בהם מוריד את כמות הדגימות, מונע צווארי בקבוק לפני כניסה לשכבת קונבולוציה ומקל על הרשת.

- Growth rate k :

עבור כל שכבה המפיקה k פילטרים, השכבה ה- ℓ תכיל $k_0 + k \times (\ell - 1)$ פילטרים כאשר k_0 הוא מספר הערוצים בקלט הכניסה. נתייחס לפרמטר k בתור קצב הצמיחה של הפילטרים ברשת. תכונה ייחודית לרשת מסוג DenseNet היא שהיא יכולה להיות בעלת קצב צמיחה קטן יחסית ועדיין להגיע לתוצאות סיווג גבוהות. ההסבר לכך הוא שלכל שכבה יש גישה לכל המאפיינים בשכבות הרשת שלפניה ולכן ניתן להתייחס למאפיינים במצב זה כגלובליים כאשר כל שכבה מוסיפה k פילטרים משלה למאגר.

Layers	Output Size	DenseNet-121($k = 32$)	DenseNet-169($k = 32$)	DenseNet-201($k = 32$)	DenseNet-161($k = 48$)
Convolution	112×112	7×7 conv, stride 2			
Pooling	56×56	3×3 max pool, stride 2			
Dense Block (1)	56×56	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$
Transition Layer (1)	56×56	1×1 conv			
	28×28	2×2 average pool, stride 2			
Dense Block (2)	28×28	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$
Transition Layer (2)	28×28	1×1 conv			
	14×14	2×2 average pool, stride 2			
Dense Block (3)	14×14	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 24$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 48$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 36$
Transition Layer (3)	14×14	1×1 conv			
	7×7	2×2 average pool, stride 2			
Dense Block (4)	7×7	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 16$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 24$
Classification Layer	1×1	7×7 global average pool			
		1000D fully-connected, softmax			

Figure 18: ארכיטקטורות DenseNet השונות. הרשת הנבחרת למחקר מודגשת מצד שמאל.

• Standard CNN Ver 2 :

אופציה נוספת לגרסת הרשת הסטנדרטית שנבחרה מתוארת בטבלה מטה. בארכיטקטורה הנוכחית בוצע שימוש בכלי נפוץ בבניית רשתות CNN.

• Early stopping :

הפונקציה נועדה למנוע Overfitting לבסיס הנתונים ע"י כך שתפסיק את תהליך האימון במידה ותזהה הגעה לתנאי רוויה עבור פרמטרים נבחרים של הפסד/דיוק. במודל הנוכחי בוצע שימוש בפרמטר loss על מנת לאמוד את מדד ההפסד בתהליך האימון.

שם השכבה	גודל היציאה	מספר פרמטרים
BN	(None, 224, 224, 3)	12
Conv2D	(None, 224, 224, 64)	1792
MaxPooling2D	(None, 112, 112, 64)	0
Dropout	(None, 112, 112, 64)	0
Conv2D	(None, 110, 110, 32)	18464
MaxPooling2D	(None, 55, 55, 32)	0
Dropout	(None, 55, 55, 32)	0
Flatten	(None, 96800)	0
Dense	(None, 128)	12390528

0	(None, 128)	Dropout
387	(None, 3)	Dense

Table 6: גרסה 2 לרשת סטנדרטית

• Vgg16:

הארכיטקטורה הנ"ל נבנתה ע"י קרן סימוניאן ואנדרדו זיסרמן מאוניברסיטת אוקספורד בשנת 2014 והיא אחת הרשתות הנפוצות בתחום הלמידה העמוקה. המבנה מכיל 13 שכבות קונבולוציה כאשר החלון של כולן בגודל קבוע 3×3 , 2 שכבות FC ופונקציית סיווג מסוג SoftMax ביציאה מהרשת. גודל הקלט בכניסה לרשת יהיה 224×224 עפ"י התכנון המקורי. אחד החסרונות הגדולים של הארכיטקטורה הוא שתהליך האימון נורא איטי לעומת רשתות אחרות אך הרשת מפצה על כך בביצועים הגבוהים שהיא מספקת. שתי כלים בהם בוצע שימוש בתהליך בניית הרשת הם Early stopping ו-ReduceLROnPlateau.

• ReduceLROnPlateau:

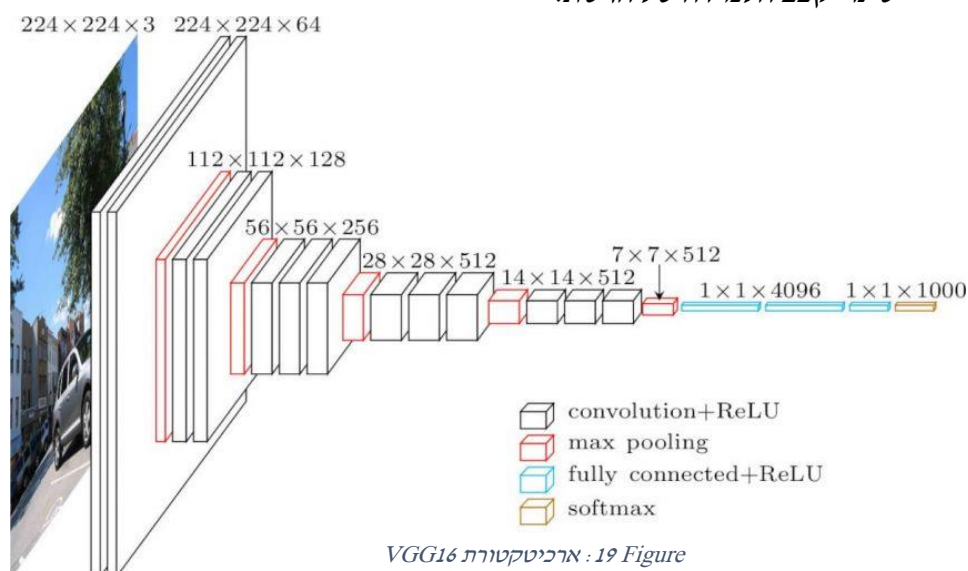
הפונקציה הנ"ל מורידה את קצב למידת הרשת בפאקטור של 0.3 במידה ורואה שאין שיפור בתהליך הלמידה במשך מספר Epochs שנבחר ע"י המשתמש. שימוש נוסף בשיטה זו נועד למנוע קפיצה גדולה מדי בעדכון המשקלים בין קבוצות הנתונים אשר נכנסים כקלט לרשת וכך לשמור על איזון בערכם.

• ניסויים שבוצעו בארכיטקטורה הנ"ל:

שינוי מספר הנוירונים בשכבת Dense.

תוספת שכבת Dropout.

שינוי קצב הלמידה של הרשת.



שם השכבה	גודל היציאה	מספר פרמטרים
Conv2D	(None, 224, 24, 32)	896
Conv2D	(None, 224, 224, 64)	18496
MaxPooling2D	(None, 112, 112, 64)	0
Conv2D	(None, 112, 112, 128)	73856
Conv2D	(None, 112, 112, 128)	147584
MaxPooling2D	(None, 56, 56, 128)	0
Conv2D	(None, 56, 56, 256)	295168
Conv2D	(None, 56, 56, 256)	590080
Conv2D	(None, 56, 56, 256)	590080
MaxPooling2D	(None, 28, 28, 256)	0
Conv2D	(None, 28, 28, 512)	1180160
Conv2D	(None, 28, 28, 512)	2359808
Conv2D	(None, 28, 28, 512)	2359808
MaxPooling2D	(None, 14, 14, 512)	0
Conv2D	(None, 14, 14, 512)	2359808
Conv2D	(None, 14, 14, 512)	2359808
Conv2D	(None, 14, 14, 512)	2359808
MaxPooling2D	(None, 7, 7, 512)	0
Flatten	(None, 25088)	0

25691136	(None, 1024)	Dense
0	(None, 1024)	Dropout
3075	(None, 3)	Dense

VGG16: 20 Figure מבנה הרשת

3.8. תהליך אימון הרשתות

כל המודלים שהוצגו אומנו מספר פעמים עבור כל רשת בהתאם לגישת K-fold CV שהוזכרה עם סט האימון שהוצג במחקר. בחירת הפרמטרים לרשתות מפורטת בטבלה מטה.

Standard CNN Ver 1.	Xception (Transfer learning)	YOLO	DenseNet121	Standard CNN Ver 2.	Vgg16	פרמטר
8	8	8	8	8	8	Batch size
150 X 150	224 X 224	224 X 224	224 X 224	224 X 224	224 X 224	Image size
Adam	Adam	Adam	Adam	Adam	Adam	Optimizer
0.0001	0.0001	0.0001	0.0001	0.0001	0.0001	LR
SoftMax	SoftMax	SoftMax	SoftMax	SoftMax	SoftMax	Activation function
Categorical cross entropy	Categorical cross entropy	Categorical cross entropy	Categorical cross entropy	Categorical cross entropy	Categorical cross entropy	Loss function
18	12	12	12	20	13	Epochs
Yes	No	No	No	Yes	Yes	Early stopping
No	No	No	No	No	Yes	ReduceLR OnPlateau

Table 7 : בחירת פרמטרים לרשתות

4. סימולציות ותוצאות

כל תוצאות המודלים הושגו על סט הבדיקה שהוצג. כל ארכיטקטורה סיווגה נתונים במשך 5 פעמים לפי שיטת ההרצה שהוצגה. להלן סיכום התוצאות:

Research	Fold No.	Accuracy	Loss	AVG Accuracy	AVG Loss
Standard CNN V1	1	0.94	0.15	0.918	0.22
	2	0.84	0.44		
	3	0.95	0.11		
	4	0.92	0.22		
	5	0.94	0.18		
Xception	1	0.937	0.19	0.937	0.2036
	2	0.94	0.21		
	3	0.95	0.178		
	4	0.91	0.33		
	5	0.95	0.11		
YOLO	1	0.9	0.22	0.9168	0.212
	2	0.914	0.24		
	3	0.94	0.14		
	4	0.89	0.29		
	5	0.93	0.17		
DenseNet	1	0.8	0.69	0.882	0.334
	2	0.83	0.43		
	3	0.97	0.07		
	4	0.94	0.14		
	5	0.87	0.34		
Standard CNN V2	1	0.88	0.29	0.856	0.334
	2	0.88	0.3		
	3	0.79	0.44		
	4	0.87	0.32		
	5	0.86	0.32		
Vgg16	1	0.948	0.14	0.9358	0.194
	2	0.925	0.28		
	3	0.938	0.18		
	4	0.91	0.26		
	5	0.958	0.11		

Table 8: תוצאות המודלים

• חישוב תוצאות הסיווג:

התוצאות חושבו עבור כל קטגוריה בנפרד עבור ארבעה פרמטרים שונים. בכל חישוב נמדדה קטגוריה אחת (positive) מול השתיים שמסלימות אותה (negative) כך שהתבצע חישוב בצורה בינארית עבור שלושת הקטגוריות הנמדדות:

$$accuracy = \frac{T_P + T_N}{T_P + T_N + F_P + F_N} \quad (11)$$

Equation 11 : accuracy

$$precision = \frac{T_P}{T_P + F_P} \quad (12)$$

Equation 12 : precision

$$recall = \frac{T_P}{T_P + T_N} \quad (13)$$

Equation 13 : recall

$$f1 - score = \frac{2 * precision}{precision + recall} \quad (14)$$

Equation 14 : f1-score

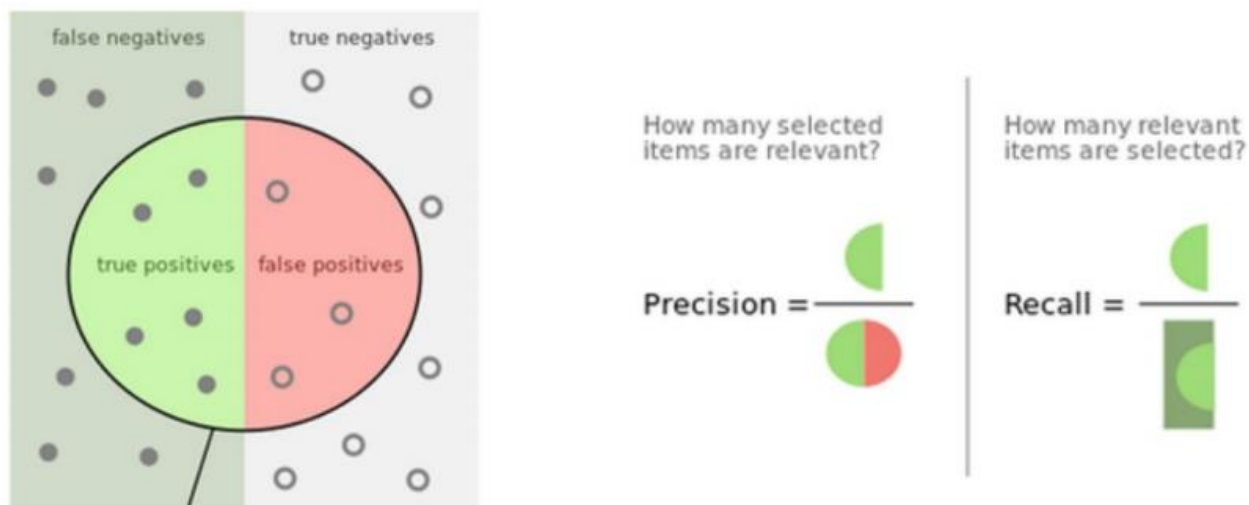


Figure 21: המחשת פרמטרים בדוח סיווג

: Standard CNN Ver 1.4.1

- ביצועי המערכת עבור רשת סטנדרטית במשך 18 Epochs. מטרתו העיקרית של הגרף היא קבלת אינדיקציה על התקדמות תהליך האימון ברשת וזיהוי מצב בו התהליך מגיע לרוויה.

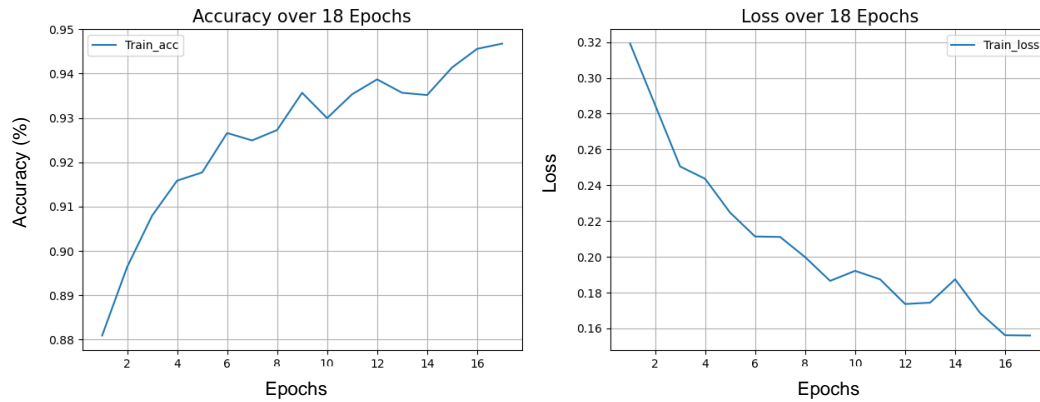


Figure 22: דיוק והפסד - רשת סטנדרטית

- מטריצות הסיווג מספקות ביצועים טובים בארבעת קבוצות הבדיקה הראשונות, בקבוצה 5 קיים קושי בסיווג דלקת ריאות רגילה.

Standard CNN

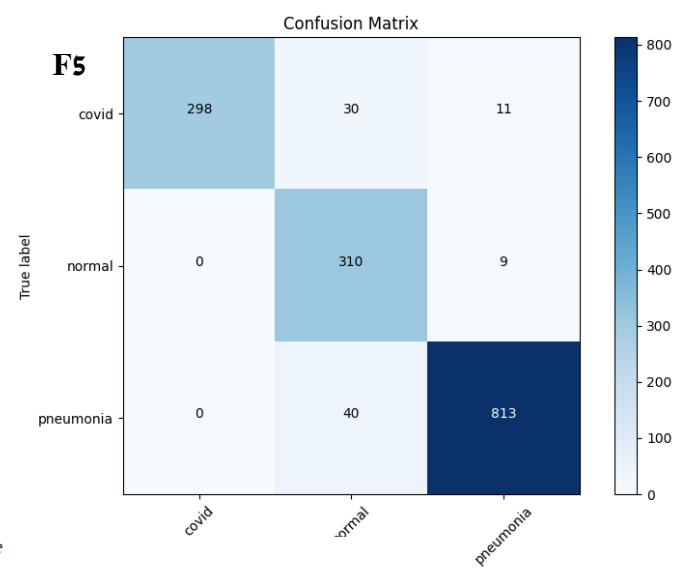
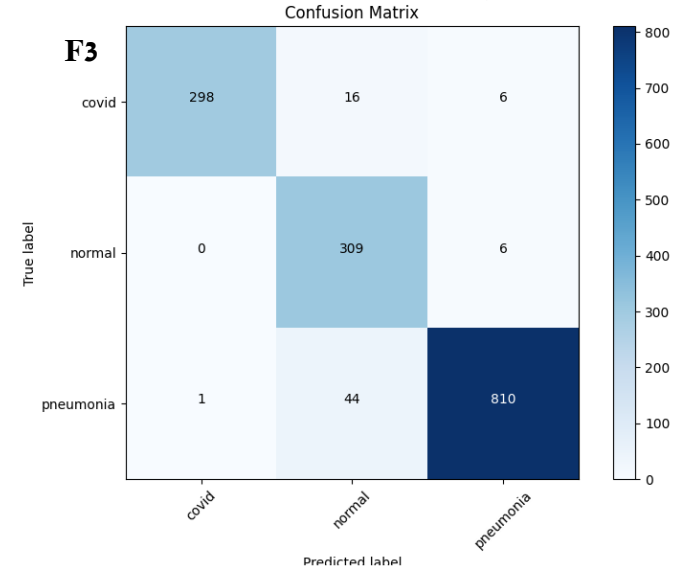





Figure 23: CM רשת סטנדרטית

- :AVG Classification Report

אחוז הדיוק הממוצע של הרשת עומד על 92% כאשר פרמטר Precision בקטגוריית Normal עומד על 80%. הגורם העיקרי לכך כאמור הוא סיווג קבוצה מס 2.

Category	Precision	Recall	f1-score
Covid-19	0.974	0.928	0.948
Normal	0.806	0.93	0.856
Pneumonia	0.966	0.916	0.936
AVG	0.915	0.924	0.913
Accuracy			0.922

Table 9: דוח סיווג ממוצע- רשת סטנדרטית

4.2.Xception:

- תהליך האימון מתבצע בצורה תקינה. ישנה ירידה קלה ב epoch מס 8.

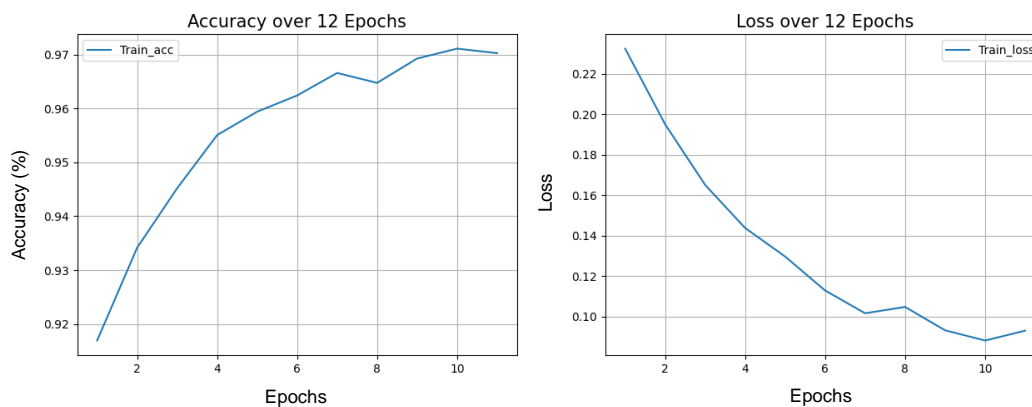



Figure 24: דיוק והפסד Xception


- מטריצות הסיווג מספקות סיווג גבוה עבור חולי קורונה ואנשים בריאים. ישנה ירידה בביצועים עבור קבוצה 2 בסיווג דלקת ריאות.

Xception


F4




F5




F1



F2



F3



Xception CM : 25 Figure

• :AVG Classification Report

אחוז הדיוק הממוצע של הרשת עומד על 94% כאשר פרמטר Precision מצביע על חולשה בקטגוריית Normal שנובע מקבוצה 2.

Category	Precision	Recall	f1-score
Covid-19	0.97	0.974	0.974
Normal	0.822	0.966	0.886
Pneumonia	0.986	0.918	0.948
AVG	0.92	0.952	0.936
Accuracy			0.94

Table 10: דוח סיווג ממוצע Xception

:YOLO 4.3

- גרף דיוק והפסד של תהליך האימון משתפרים עם התקדמות התהליך ומתנהגים לפי הציפיות.









Figure 26: דיוק והפסד YOLO

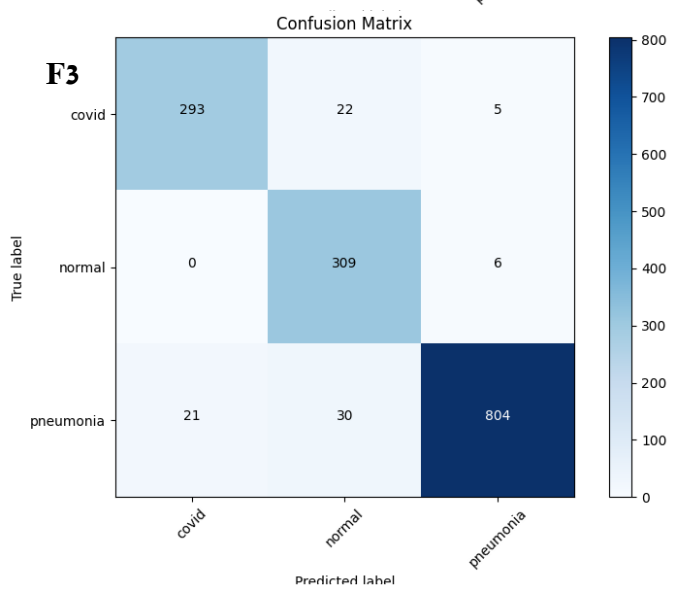




- בוצע מקצה שיפורים בניסיון לשפר את תוצאות הסיווג של הרשת. בריצה ראשונה התקבלו תוצאות סבירות ובהתמקדות בקבוצה 3 ניתן לזהות סיווג בעייתי בין שלושת הקטגוריות. במקצה השני מטריצות הסיווג מעידות על שיפור ניכר בקבוצה 3 וירידה קלה בביצועים עבור קבוצות 1,4.

YOLO - לפני שיפור



YOLO CM : 27 Figure

YOLO - לאחר שיפור



YOLO CM : 28 Figure לאחר שיפור

• :AVG Classification Report

תוצאות דיוק מרשימות של 91% בממוצע עבור כל חמשת קבוצות הבדיקה לאחר שיפור וביצוע ניסויים ברשת על פרמטרים נלמדים. בגרסה הראשונה הרשת עמדה על 86% דיוק. בקטגוריית Precision עבור קורונה ישנם 95%- משמע הרשת מכילה כמות מאוד קטנה של FP. עבור Normal ישנה עליה בכמות FP אשר נובעת מקבוצות 1,4 בעיקר.

Category	Precision		Recall		f1-score	
Covid-19- before & after	0.852	0.948	0.96	0.95	0.878	0.946
Normal- before & after	0.812	0.784	0.926	0.938	0.864	0.88
Pneumonia- before & after	0.972	0.978	0.806	0.902	0.852	0.936
AVG	0.903		0.93		0.910	
Accuracy- before & after					0.864	0.916

Table 11 : דוח סיווג ממוצע YOLO

4.4 :DenseNet

- ישנה דעיכה קלה ב epoch מס' 8 בתהליך האימון.









Figure 29 : דיוק והפסד DenseNet

- ניתן לראות קושי בזיהוי של דלקת ריאות רגילה בקבוצות הבדיקה 1,2.

DenseNet



DenseNet CM : 30 Figure

• :AVG Classification Report

דיוק ממוצע ברשת של 88% שמספק ביצועים סבירים, הטעויות הם בעיקר עבור דלקת ריאות. חלק מהתמונות בקטגוריה זו מסווגות עבור אנשים בריאים. ניתן לראות זאת באחוזי Precision.

Category	Precision	Recall	f1-score
Covid-19	0.98	0.932	0.952
Normal	0.706	0.972	0.806
Pneumonia	0.98	0.83	0.898
AVG	0.888	0.911	0.885
Accuracy			0.882

Table 12 : דוח סיווג ממוצע DenseNet

4.5 :VGG16

- תהליך האימון מתקדם לפי הציפיות וישנו שיפור מתמיד.









Figure 31 : דיוק והפסד VGG16

- מטריצות הסיווג מעידות על ביצועים גבוהים מאוד בתהליך הסיווג של כל קבוצות הבדיקה והתוצאות מספקות.

VGG16



VGG16 CM : 32 Figure

- **AVG Classification Report :**

הרשת מספקת אחוז דיוק ממוצע מרשים של 94%. הפרמטר Precision עבור הקטגוריה Normal עומד על 85% ובדומה לשאר הרשתות חלק מהתמונות בקטגוריות הדלקת מסווגות כתקינות, אם כי הפעם חלק נמוך יותר.

Category	Precision	Recall	f1-score
Covid-19	0.978	0.936	0.956
Normal	0.856	0.908	0.88
Pneumonia	0.954	0.948	0.95
AVG	0.929	0.93	0.928
Accuracy			0.94

Table 13: דוח סיווג ממוצע VGG16

- **Standard CNN Ver2.4.6 :**

- הרשת מתקדמת בתהליך האימון לפי הציפיות וישנה עליה תמידית במהלך ה Epochs.




Figure 33: דיוק והפסד רשת סטנדרטית- גרסה 2

- ביצועים יחסית טובים בסיווג הקטגוריות ע"י מטריצות הסיווג. ישנה ירידה קלה בסיווג בקבוצה 3 עבור דלקת ריאות רגילה.

Standard CNN Ver. 2








Figure 34: CM רשת סטנדרטית- גרסה 2

• :AVG Classification Report

ישנה ירידה באחוז הדיוק הממוצע לעומת [גרסה 1](#) של הרשת הסטנדרטית. בפרמטר Precision בקטגוריית Normal ישנה חולשה המעידה על קושי בשיוך לקטגוריה זו. ניתן לראות זאת בקבוצה 3 במטריצות הסיווג.

Category	Precision	Recall	f1-score
Covid-19	0.98	0.856	0.912
Normal	0.64	0.956	0.764
Pneumonia	0.966	0.824	0.888
AVG	0.862	0.878	0.854
Accuracy			0.86

Table 14: דוח סיווג ממוצע - רשת סטנדרטית גרסה 2

5. בעיות הנדסיות ודרכי התמודדות

- הגבלת סט הבדיקה :
עקב מגבלת כמות התמונות בסט הבדיקה החשש הוא שתוצאות האימון מותאמות לבסיס נתונים ספציפי (Overfitting). לכן הרשתות אומנו בשיטת 5-Fold CV וכך הייתה אפשרות לבדוק יותר מסט אחד של תמונות שהרשתות אינן מכירות. כך הייתה סבירות גבוהה יותר להעריך את היכולות של כל רשת ואת רמת ההכללה שלה עבור נתונים שהיא איננה מכירה.
- זמני אימון ומגבלות זיכרון של רשתות למידה עמוקה :
בתהליך האימון הרשתות אומנו בשיטת 5-Fold CV אשר מריצה את תהליך האימון חמש פעמים ברצף עם סטים שונים כל בדיקה בכל הרצה. עקב זמן הריצה הארוך של התהליך והזיכרון המוגבל כל רשת רצה בנפרד עבור כל קבוצת נתונים והתוצאות נשמרו לאחר כל הרצה זאת על מנת למנוע זמן אימון ארוך וזיכרון רב מהמערכת.
- הגעה לאחוזי דיוק גבוהים :
במהלך בניית הרשתות האתגר המרכזי היה הגעה לאחוזי דיוק של 90% ומעלה. לאחר בחירת פרמטרים והרצת תהליכי אימון בארכיטקטורת VGG16 לא היה שיפור בביצועי הרשת. על מנת להתמודד עם בעיה זו ולהמשיך לשפר את המשקלים בוצע שימוש בפונקציה בשם ReduceLROnPlateau להורדת קצב הלמידה (LR) של הרשת לקצב איטי יותר עם פקטור של 0.3 ובכך להמשיך ולהעלות את אחוזי הדיוק של הרשת. בנוסף על מנת להתמודד עם בעיית סיווג לקטגורית Normal עבור שתי ארכיטקטורות (YOLO, Standard V2) ננקטו שתי דרכים : בנייה עצמאית של גרסה סטנדרטית (V1) אשר הציגה שיפור באחוז Precision ושינוי גודל חלון הקונבולוציה (YOLO) ששיפר את מטריצות הסיווג.
- הכרות עם עולם הלמידה העמוקה :
במהלך המחקר נחשפתי לעולם רחב של מושגים בתחום הלמידה העמוקה אשר את חלקם לא הכרתי קודם לכן. ישנו מגוון רחב של כלים לצורך בניית רשת למידה עמוקה וכדי לתכנן רשת מוצלחת צופה ממני שאכיר את כולם. על מנת להתמודד עם בעיה זו עשיתי עבודת חקר מקדימה שכללה קריאה של המון חומרים בתחום והעשירה את עולם המושגים שלי והכלים שאוכל להשתמש בהם. בנוסף למדתי סוגים שונים של ארכיטקטורות על מנת שאוכל להבין את ההבדלים והמאפיינים של כל אחת מהן ואדע כיצד לעשות בהן שימוש.

6. סיכום ודיון

מטרת המחקר המרכזית היא בחינת ארכיטקטורות למידה עמוקה לסיווג Covid-19 אשר מתפשט בשנה וחצי האחרונות. בתחילת המחקר הוצב יעד של סיווג בדיוק גבוה של מעל 90% בו המחקר עמד בהצלחה. ישנם מספר נקודות עיקריות במחקר זה:

- בניית ארכיטקטורות מסוג CNN/Resnets ובחינת דרך פעולתם ותכונות עיקריות של כל רשת.
- בניית בסיס נתונים נרחב של תמונות רפואיות לצורך בדיקתו ברשתות שלעיל.
- התבססות על מחקרים קודמים בנושא תוך כדי בדיקה וניתוח תוצאות של הארכיטקטורות הנבנות במחקר, דרכי פעולה ויישומם ברשתות הנבנות יחד עם בסיס הנתונים שנוצר.
- ניתוח התוצאות שהתקבלו והשוואת ביצועים בין הארכיטקטורות בהן נעשה שימוש.

הארכיטקטורות שנבחנו היו ארכיטקטורות נפוצות בתחום הלמידה העמוקה ונבנו באופן מותאם לסיווג הבעיה שהוצגה תוך כדי שימוש בבסיס נתונים מורחב שנבנה במיוחד לצורך המחקר הנ"ל אשר מכיל שלושה קטגוריות בדיקה.

הארכיטקטורות נבחרו בעקבות מחקרים קודמים בנושא שנבחנו על בסיס נתונים קטן יחסית שנבנה בתחילת המגיפה ולכן לא היו מספיק מקורות ליצירת בסיס נתונים גדול. בסיס הנתונים שהוצג גדול מספיק על מנת לקבוע האם הארכיטקטורות הנבנות אכן מתאימות למשימה הנ"ל ולכן בעקבות התוצאות תוכל להינתן ולידציה שאכן הסיווג מתבצע באחוזים גבוהים גם עבור בסיס נתונים רחב ומוכלל באמצעות האלגוריתמים הנפוצים של הלמידה העמוקה.

6.1. הליך קבלת החלטות לאורך הפרויקט

הליך קבלת ההחלטות התחיל בכך שהחלטתי לבצע עבודת חקר מקדימה על בניית רשתות CNN על מנת לקבל הבנה טובה יותר ולהעשיר את הידע שלי בנושא. במהלך שלב זה למדתי שכדי להריץ רשתות בסביבת GPU עלי להתקין תוסף של CUDA - סט פקודות API אשר מאפשר שימוש ביחידת עיבוד גרפית שנמצאת במחשב (GPU). ביחידה זו משתמשים כדי לבצע חישובים מתמטיים בקצב גבוה אשר דרוש לרשתות מסוג זה.

לאחר ההכנה הדרושה התחלתי לאסוף תמונות רפואיות לבניית בסיס הנתונים ממקורות שסיפק לי אמיר וכמו כן קריאת מחקרים בנושא ותוצאות שהושגו. לאחר הרצת כמה רשתות על מנת לקבל אינדיקציה ראשונית עבור בסיס הנתונים שבניתי קיבלתי מספר פידבקים מאמיר:

- עבור תהליך ניתוח התוצאות לכל רשת שתיבנה במחקר הבנתי שעלי להשתמש ככלי עיקרי במטריצות סיווג (Confusion Matrixes). זאת מפני שבמחקר בסדר גודל כזה בעל יותר מקטגוריות סיווג אחת אחוזי הדיוק של הרשת יכולים להיות גבוהים אך עדיין אם נתעמק בתוצאות בכל קטגוריה בנפרד (ובקטגוריה המרכזית שהיא קורונה בפרט) אנו עלולים לקבל תוצאות שהן אינן משתמעות לשתי פנים. הסיבה לכך היא אפשרות שהתוצאות עבור קטגוריה אחת יהיו גבוהות

ולמעשה יצרו אפקט מטעה על תוצאות כלל הרשת ולכן הכלי היעיל ביותר לשימוש יהיה מטריצות הסיווג שעבורם נוכל לקבל תוצאות אמינות ומדויקות עבור כל קטגוריה בנפרד.

- על מנת לבדוק כל רשת כמה וכמה פעמים כדי לאמת את אמינות התוצאות ובנוסף כדי למנוע בעיות זיכרון חילקתי את בסיס הנתונים שבניתי לחמש חלקים כנהוג בשיטת 5-Fold CV. כך יכולתי להריץ כל אחת מהרשתות מספר פעמים על נתונים שונים בכל פעם ולבחון את אמינות התוצאות של כל רשת באמצעות ממוצעים.

שלב בחירת הארכיטקטורות ובניית הרשתות:

עבור בחירת סוגי הרשתות לאחר קריאת עשרות מאמרים החלטתי על בניית 5 סוגי הרשתות אשר מוצגות מעלה באופן מפורט. באופן כללי ההחלטות עבור כל בחירה נבעו מהתוצאות הגבוהות ביותר שהושגו במחקרים קודמים ומעבר על ביצועים והצלחות נוספות מלבד נושא זה של הארכיטקטורות השונות. ההחלטה שלקחתי בחלק זה היא התמקדות ראשית בבניית הליבה של כל רשת והגעה לרף מינימלי ראשוני של סיווג ולאחר מכן השקעתי מאמץ בשיפור ביצועי כל רשת בנפרד באמצעות ניסויים ובחירת פרמטרים מתאימים. לבסוף ריכזתי את כלל התוצאות שהתקבלו, בוצע הליך הסקת מסקנות וכתיבת ספר זה אשר מסכם את המחקר שערכתי.

6.2. תרומת עבודתו של הסטודנט

- עבודה מקדימה וחקר מעמיק על כל עקרונות הלמידה העמוקה וסביבת העבודה הדרושה.
- בדיקת 4 סוגי אלגוריתמים נפוצים בלמידה עמוקה.
- הוספת אלגוריתם עפ"י העקרונות המקובלים של למידה עמוקה.
- בניית בסיס נתונים רחב של תמונות רפואיות אמיתיות המכילות קורונה, דלקת ריאות, אנשים בריאים.
- ביצוע ניסויים על שלושה אלגוריתמים לצורך שיפור ביצועי הרשת.
- הסקת מסקנות מהרשתות שנבנו והשוואות בין ביצועים ותוצאות.
- כתיבת ספר המתעד את הארכיטקטורות אשר נבחרו לביצוע המחקר ומסכם את תקופת העבודה.

6.3. שינויים עתידיים דרושים והצעות לשיפור

- מציאת ארכיטקטורות אשר יציגו ביצועים משופרים בסיווג דלקת ריאות רגילה יחד עם שילוב Covid-19.
- הצעה לפתרון בעיית הסיווג הנ"ל לצורך מענה מהיר לבדיקות Covid-19 היא בניית רשתות בינאריות עבור הנגיף בלבד וכך יינתן פתרון (לפחות באופן זמני) עקיף אשר יתמודד עם בעיה זו.
- אפשרות נוספת אשר תעלה משמעותית את אמינות תוצאות הסיווג היא יצירת אלגוריתם פענח אשר יסתמך על הסתברות ווקטורית של חמשת הארכיטקטורות המוצגות במחקר ויסווג תמונות לפי חישוב ווקטור היציאה המשוכלל של כלל הרשתות.

דוגמה עבור דגימת חולה Covid-19 בעל ווקטור כניסה לרשתות של $[1 \ 0 \ 0]$:
ווקטור היציאה שנקבל עבור [Standard CNN V1](#):

$$\sigma(\vec{z})_1 = 0.952 \quad \sigma(\vec{z})_2 = 0.0474 \quad \sigma(\vec{z})_3 = 0.0003 \quad (15)$$

$$[0.952 \ 0.0474 \ 0.0003]$$

ווקטור היציאה עבור [Exception](#):

$$\sigma(\vec{z})_1 = 0.366 \quad \sigma(\vec{z})_2 = 0.523 \quad \sigma(\vec{z})_3 = 0.111 \quad (16)$$

$$[0.366 \ 0.523 \ 0.111]$$

ווקטור היציאה עבור [YOLO](#):

$$\sigma(\vec{z})_1 = 0.61 \quad \sigma(\vec{z})_2 = 0.056 \quad \sigma(\vec{z})_3 = 0.334 \quad (17)$$

$$[0.61 \ 0.056 \ 0.334]$$

ווקטור היציאה עבור [DenseNet](#):

$$\sigma(\vec{z})_1 = 0.2001 \quad \sigma(\vec{z})_2 = 0.0189 \quad \sigma(\vec{z})_3 = 0.781 \quad (18)$$

$$[0.2001 \ 0.0189 \ 0.781]$$

ווקטור היציאה עבור [VGG16](#):

$$\sigma(\vec{z})_1 = 0.971 \quad \sigma(\vec{z})_2 = 0.02 \quad \sigma(\vec{z})_3 = 0.009 \quad (19)$$

$$[0.971 \ 0.02 \ 0.009]$$

חישוב ווקטור היציאה המשוכלל יתבצע לפי פונקציית AVG של כל רכיב בקטגוריה בנפרד:

$$\sigma(\vec{z})_1 = \frac{(0.952+0.366+0.61+0.2001+0.971)}{5} = 0.619 \quad (20)$$

$$\sigma(\vec{z})_2 = \frac{(0.0474+0.523+0.056+0.0189+0.02)}{5} = 0.133 \quad (21)$$

$$\sigma(\vec{z})_3 = \frac{(0.0003+0.111+0.334+0.781+0.009)}{5} = 0.247 \quad (22)$$

$$[0.619 \ 0.133 \ 0.247]$$

Equation 15: הצעת אלגוריתם יציאה משופר

6.4. מסקנות

- כל האלגוריתמים הנבחנים עובדים ועונים על מטרת המחקר המרכזית של סיווג גבוה כאשר ארבעה מהם מסווגים בדיוק של מעל 90% ועונים על הציפיות בתחילת המחקר. האלגוריתמים VGG16, Xception הגיעו לתוצאות מצוינות של 94% דיוק והם המוצלחים ביותר ללא ספק במחקר זה.
- כמוות התמונות היא גבוהה מספיק על מנת לתת ולידציה לאלגוריתמים הנ"ל אשר עומדים במבחן של בסיס נתונים מגוון ומוכלל.
- ניתן לשפר את ההישגים אף יותר אך באחוזים גבוהים של 90% ומעלה כל שיפור מצריך זמן עבודה רב שדורש מחקר נוסף.
- ברוב האלגוריתמים במטריצות הסיווג נרשם בלבול בין דלקת ריאות רגילה לצילום של אדם בריא. נתון מובהק לכך הוא אחוזי ה Precision בקבוצת Normal. בכל הרשתות ניתן לראות כי נתון זה הראה חולשה לעומת שאר הקטגוריות וברשת המוצלחת ביותר עמד על 85%. הנושא מצריך בדיקה נוספת על מנת להבין מהיכן נובעת הטעות הנ"ל. אחד הגורמים האפשריים לכך הוא גודלה של קבוצת התמונות של דלקת ריאות לעומת קורונה ואנשים בריאים.
- בכל הנוגע לנתוני סיווג של Covid-19 המחקר הראה על הצלחה בכל הרשתות שהוצגו. בדוחות נצפו אחוזים גבוהים בשלושת הפרמטרים המחושבים Precision, Recall, f1-score בסיווג הקטגוריה המעידות על למידה מובהקת של מאפייני הנגיף בצילומי X-Ray והיבדלותו משני הקטגוריות האחרות במחקר.

- [1] "Dive into Deep Learning", Aston Zhang, Zachary C. Lipton, Mu Li, and Alexander J. Smola, January 2019.
- [2] "Deep Dive into Different Types of Convolutions for Deep Learning", Amir Hossein Karami, January 2019.
- [3] "CoroNet: A deep neural network for detection and diagnosis of COVID-19 from chest x-ray images", Asif Iqbal Khan, Junaid Latief Shah, and Mohammad Mudasar Bhat.
<https://www.sciencedirect.com/science/article/abs/pii/S0169260720314140#sec0002>
- [4] "Automated detection of COVID-19 cases using deep neural networks with X-ray images", Tulin Ozturk, Muhammed Talo, Eylul Azra Yildirim, Ulas Baran Baloglu, Ozal Yildirim, U. Rajendra Acharya,
<https://www.sciencedirect.com/science/article/abs/pii/S0010482520301621>
- [5] "Depth-wise Convolution and Depth-wise Separable Convolution", Atul Pandey, September 2018,
<https://medium.com/@zurister/depth-wise-convolution-and-depth-wise-separable-convolution-37346565d4ec>
- [6] "Diagnosing Covid-19 chest x-rays with a lightweight truncated DenseNet with partial layer freezing and feature fusion", Francis Jesmar P. Montalbo,
<https://www.sciencedirect.com/science/article/abs/pii/S1746809421001804#sec0115>
- [7] "TLCoV- An automated Covid-19 screening model using Transfer Learning from chest X-ray images", Ayan Kumar Das, Sidra Kalam, Chiranjeev Kumar, Ditipriya Sinha,
<https://www.sciencedirect.com/science/article/abs/pii/S0960077921000667#sec0004>

- [8] "Explainable Deep Learning for Pulmonary Disease and Coronavirus COVID-19 Detection from X-rays", Luca Brunese, Francesco Mercaldo, Alfonso Reginelli, Antonella Santone,
<https://www.sciencedirect.com/science/article/abs/pii/S0169260720314413#sec0002>

- [9] "COVID-19 X-ray database", an open source Github repository, Joseph Paul Cohen
<https://github.com/ieee8023/covid-chestxray-dataset>

- [10] "Curated Chest X-Ray Image Dataset for COVID-19", Unais Sait, September 2020.
<https://data.mendeley.com/datasets/9xkhgts2s6/1>

- [11] Labeled Optical Coherence Tomography (OCT) and Chest X-Ray Images for Classification, Daniel Kermany, June 2018.
<https://data.mendeley.com/datasets/rscbjbr9sj/2>

- [12] Dr. Amir Adler, Deep learning lecture notes, Braude Collage of Engineering, 2019

- [13] "A High-Accuracy Model Average Ensemble of Convolutional Neural Networks for Classification of Cloud Image Patches on Small Datasets", Van Hiep Phung and Eun Joo Rhee, Department of Computer Engineering, Hanbat National University, October 2015.
https://www.researchgate.net/publication/336805909_A_High-Accuracy_Model_Average_Ensemble_of_Convolutional_Neural_Networks_for_Classification_of_Cloud_Image_Patches_on_Small_Datasets

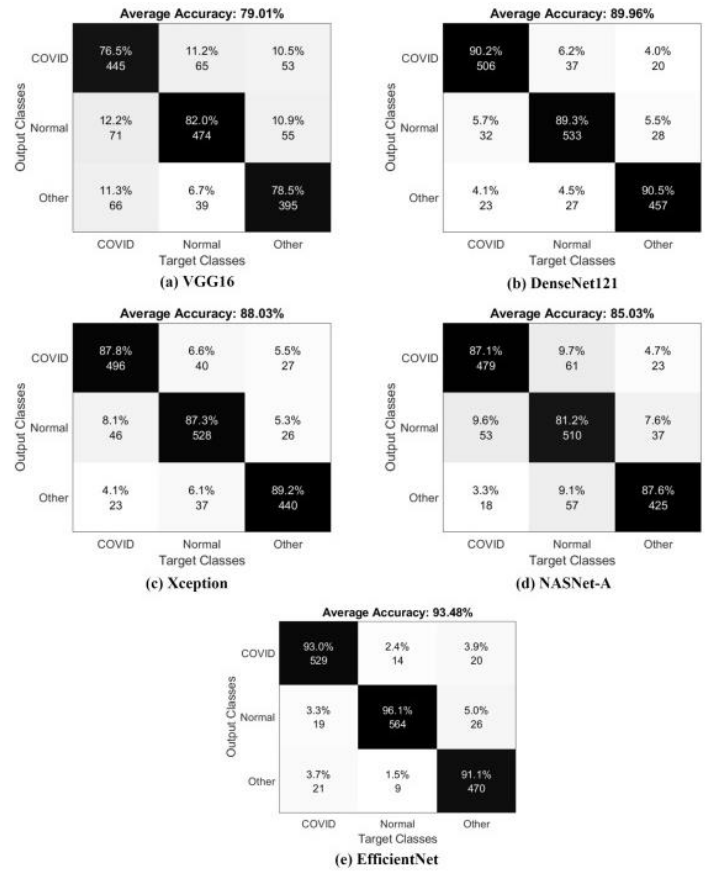
- [14] "Covid-19: Automatic detection from X-ray images by utilizing deep learning methods", Bhawna Nigam, Ayan Nigam, Rahul Jain, Shubham Dodia, Nidhi Arora, B. Annappa, Institute of Engineering and Technology, Devi Ahilya University, August 2021.
<https://www.sciencedirect.com/science/article/pii/S0957417421003249>

8. נספחים

נספח א':

בתמונה: ביצועי רשתות במסגרת מחקרים בעלי סדר גודל זהה מהתקופה הנוכחית

Performance measures	VGG16	DenseNet121	Xception	NASNet	EfficientNet
Batch size	32	32	32	32	32
Image dimension	512 × 512	512 × 512	512 × 512	512 × 512	512 × 512
Optimizer	Adam	Stochastic Gradient Descent	Adam	Adam	Adam
Learning rate	1e-4	1e-4	1e-4	1e-4	1e-3
Decay rate	1e-5	1e-5	1e-5	1e-5	1e-4
Activation function	Softmax	Softmax	Softmax	Softmax	Softmax
Loss function	Weighted binary cross entropy	Weighted binary cross entropy	Weighted binary cross entropy	Categorical cross entropy	Categorical cross entropy
Training accuracy	80.32%	92.98%	90.84%	89.99%	97.17%
Testing accuracy	79.01%	89.96%	88.03%	85.03%	93.48%



Performance measures	Class	VGG16	DenseNet121	Xception	NASNet	EfficientNet
Precision	COVID	79%	90%	88%	85%	93%
Precision	Normal	79%	90%	88%	85%	94%
Precision	Other	79%	90%	88%	85%	93%
Recall	COVID	76%	90%	88%	87%	93%
Recall	Normal	82%	89%	87%	81%	93%
Recall	Other	79%	90%	89%	88%	91%
F1 Score	COVID	0.78	0.90	0.88	0.86	0.93
F1 Score	Normal	0.80	0.90	0.88	0.83	0.94
F1 Score	Other	0.79	0.90	0.89	0.86	0.93

9. קורות חיים

כתובת : קריית ביאליק

טלפון : (+972) 052-5188980

דוא"ל : moshikonisim@gmail.com

Linked-In : www.linkedin.com/in/moshe-nissim-117821134

תמצית

סטודנט להנדסת חשמל ואלקטרוניקה- התמחות תוכנה ומחשבים. בעל ניסיון במספר שפות תכנות, פיתוח כלים ותהליכי Reliability.

ניסיון תעסוקתי

- 2019-2020 : Western Digital - משרת סטודנט במעבדות WD :

עיקרי התפקיד :

- * יצירת אוטומציה/יכולות תקשורת לסביבת תנורים במעבדות.
- * תמיכה בבדיקות מוצרי iNAND בסביבות מעבדה אוטומטיות.
- * עבודה עם מגוון פלטפורמות בדיקה יעודיות, תנורים וציוד מדידה.
- * תמיכה בבקשות הנדסה יעודיות (התאמה אישית של בדיקות).
- * אחר : עבודה עם כלים ארגוניים, DB, Jira, FAR, PowerBI, כלים כיוול, ניתוח כשלים ראשוני.

- 2014-2016 : אשד אוטומציה- מפעל אלקטרוניקה- חוות לוחות ומערכות אלקטרוניות.

התמחויות

- 2020-2021 : תכנון ארכיטקטורות למידה עמוקה במכללת אורט בראודה.

סביבות עבודה

- Microsoft Visual studio (C/C++ programming)
- PyCharm (Python programming)
- ModelSim-Altera (VHDL)
- Linux environment

השכלה

- 2016-2021 : סטודנט להנדסת חשמל ואלקטרוניקה במכללת האקדמית אורט בראודה בכרמיאל.
- 2015-2016 : סטודנט במכינת הטכניון.
- 2010 : בוגר בית הספר ניר העמק בעפולה- תעודת בגרות מלאה הכוללת מגמת אלקטרוניקה ומחשבים.

שירות צבאי

- 2010-2013 : שירות בחטיבה 474 ברמת הגולן בתור טכנאי אלקטרוניקה בגדר המערכת (חייל חימוש). שחרור בדרגת סמ"ר. מצטיין קחש"ר.

מעורבות חברתית ותרומה לקהילה

- 2016-2021 : סטודנט במלגת "קרן מושל", ליווי וחניכה של סטודנטים חדשים במלגה עם כניסתם לאקדמיה.
- 2020-2021 : השתתפות בתוכנית מנטורים מטעם מגדלור להשתלבות בתעשייה.